Documentação Arquitetural - Plataforma NÓDULO

1. Visão Geral do Sistema

O **NÓDULO** é uma plataforma de Inteligência Artificial Soberana e de código aberto. Concebido com o objetivo de oferecer capacidades de nível empresarial (semelhantes ao ChatGPT Plus e Perplexity AI) garantindo total privacidade e controle de dados. O ecossistema é baseado numa arquitetura de microsserviços gerida num Monorepo, utilizando **Go** (Backend), **Next.js** (Frontend) e **PostgreSQL com pgvector** (Memória e Banco de Dados), orquestrados via **Docker**.

2. Infraestrutura Híbrida e Inferência

Para viabilizar o uso de Modelos de Linguagem de Grande Escala (LLMs) pesados sem custos exorbitantes de hardware local, a plataforma adota uma infraestrutura de inferência híbrida:

- **Cérebro (Computação em Nuvem Efêmera):** Processamento matemático executado em instâncias de GPU A100 (via Google Colab/RunPod) utilizando o motor **Ollama**. A conexão é blindada através de um **Cloudflare Tunnel**, permitindo escalabilidade sob demanda.
- **Memória (Soberania Local):** Todo o armazenamento, vetorização de dados e histórico de conversas ocorrem no backend local (Go + PostgreSQL), garantindo que nenhum dado sensível do utilizador ou da instituição seja retido pelos nós de inferência.

Modelos Adotados:

- **Texto e Lógica:** `qwen2.5-coder:32b` (Alta capacidade de raciocínio, Tool Calling e programação).
- **Visão Computacional:** `llava` (Processamento de imagens, leitura de diagramas e equações).
- **Embeddings:** `nomic-embed-text` (Vetorização semântica).

3. Os Seis Pilares Tecnológicos (Capacidades)

3.1. RAG Institucional Soberano (Retrieval-Augmented Generation)

Processamento assíncrono de documentos. Textos institucionais são vetorizados no PostgreSQL (`pgvector`). Quando uma pergunta corresponde ao domínio interno, o Go recupera os blocos de texto mais relevantes e os injeta no contexto da IA, eliminando alucinações.

3.2. Agente ReAct e Pesquisa Web (Deep Research)

Implementação do padrão *Reason + Act* (ReAct). Para perguntas fora da base local, o Go atua como orquestrador, permitindo que a IA gere termos de busca, navegue na internet de forma autônoma, baixe o código HTML puro das páginas e sintetize respostas complexas com citações precisas no formato Markdown.

3.3. Roteamento Multimodal (Córtex Visual)

Um "Bypass" arquitetural no backend em Go. Se o payload do utilizador contiver uma imagem (convertida em Base64 pelo frontend), o Go isola a requisição da pipeline de texto tradicional e envia diretamente ao modelo de visão (`llava`), permitindo a análise matemática e visual de quadros negros, diagramas UML e código-fonte fotografado.

3.4. Advanced Data Analysis (Sandbox Python Isolado)

Para cálculos exatos e geração de gráficos, o modelo escreve scripts em Python. O backend intercepta o código e instancia um contêiner **Docker efêmero e isolado** (`--network none` , recursos limitados). O script é executado localmente e o Go captura o resultado no `stdout` ou gráficos (`/tmp/plot.png` em Base64), retornando à interface de forma segura e determinística.

3.5. Memória Semântica de Longo Prazo (Tutor Inteligente)

Goroutines em Go extraem silenciosamente o perfil do utilizador (dificuldades técnicas, preferências didáticas) após cada interação. Estes fatos são vetorizados e guardados na tabela `user_memory` . Em conversas futuras, o Go injeta estas memórias no *System Prompt*, garantindo uma personalização didática contínua (Empatia Artificial).

3.6. Persistência de Sessão e Auto-Title (UX)

Histórico completo gravado no banco de dados (`conversations` e `messages`). Goroutines paralelas geram títulos descritivos para novas sessões automaticamente, e o Next.js atualiza o roteamento dinamicamente sem recarregar a página, entregando uma Experiência de Utilizador (UX) de nível empresarial.